2 数据获取和异常数据处理

2.1 数据获取

实验数据来源于江苏无锡长江水质实时监测站，时间范围 2009.9.1-2017.11.21，监测频率每天一条溶解氧数据，共计 3000 条数据，单位 mg/L，采集的数据主要是耗氧量（Oxygen Consumption）、氨氮化合物（Ammonia Nitrogen）、酸碱度（pH）、溶解氧（Dissolved Oxygen）。

2.2 异常检测

2.2.1 数据分析与归一化

实验数据分布如下：

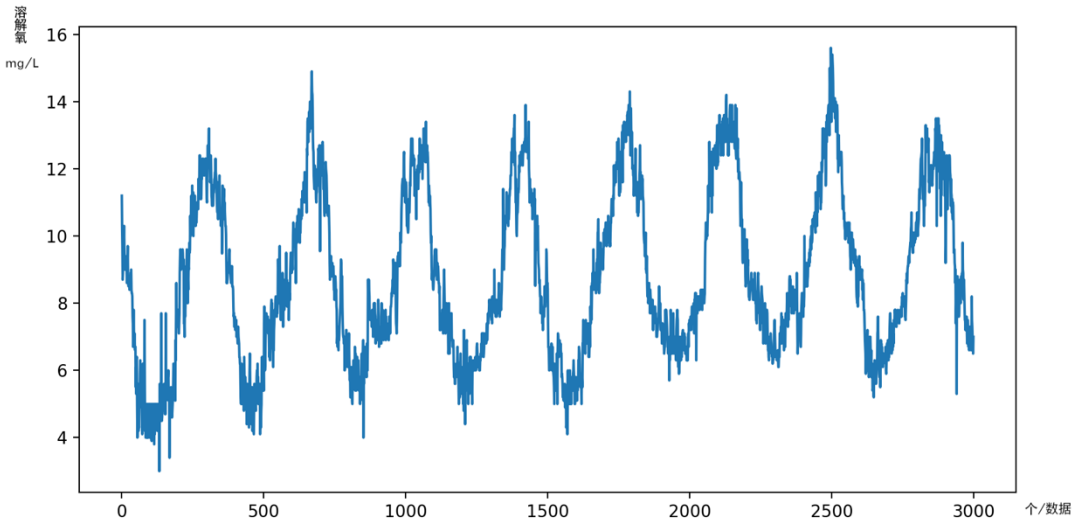


图 2-1 溶解氧原始数据分布

Figure 2-1 Dissolved oxygen raw data distribution

由于没有缺失值、零值，因此插值填充操作无需进行。但是，带有大量未缩放数据的大量输入将减慢学习速度和深度学习模型的收敛，因此，首先进行归一化处理，使用公式（1）来规范化数据并将其范围映射为 0 到 1。

$$y = (x - min)/(max - min) \quad (1)$$

其中，y 是归一化后的溶解氧数据，x 是原始溶解氧数据，max 是溶解氧数据总样本集中的最大值，min 是溶解氧数据总样本集中的最小值。然后将数据分为 85%训练集和 15%测试集。 此外，在训练数据中，我们设置了 10%的验证集。归一化后的溶解氧数据分布如下：

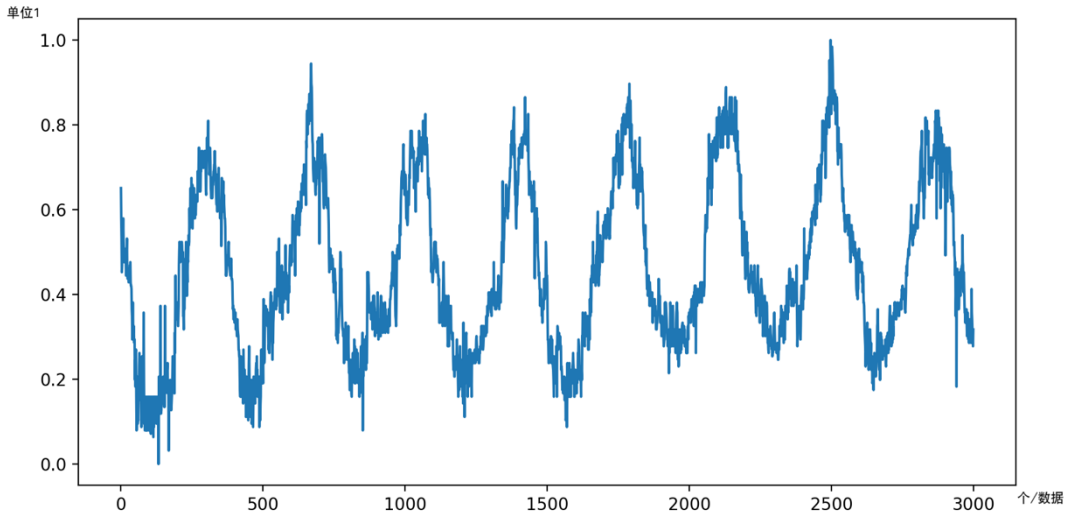


图 2-2 归一化后的溶解氧数据分布

Figure 2-2 Normalized dissolved oxygen data distribution

2.2.2 基于孤立森林算法的异常检测算法

归一化处理后，为了避免异常的溶解氧数据对正常数据的干扰、对预测功能的影响，需要进行异常检测并处理异常数据。常用的有四种异常检测的方法：Isolation Forest（孤立森林）算法、DBSCAN(Density-Based Spatial Clustering of Applications with Noise)算法、OneClassSVM（一类支持向量机）算法、Local Outlier Factor（LOF）算法。其中，孤立森林算法不是基于距离和密度判断异常，其特点是计算量小、天生可以分布式训练和计算，非常适合海量数据的场景，适用于溶解氧等水文参数时间序列的异常检测[18]。

孤立森林算法由刘飞、周志华等人[19]在 2008 年提出，具体来说，该算法利用一种名为孤立树的二叉搜索树结构来孤立样本。由于异常值的数量较少且与大部分样本的疏离性，因此，异常值会被更早的孤立出来，也即异常值会距离的根节点更近，而正常值则会距离根节点有更远的距离。iForest 森林也由大量的树组成，iForest 中的树叫 isolation tree，简称 iTree。每棵树的的学习过程非常随机：它会随机抽取特征、随机选取分割值来建立决策树，从而将每一个样本分到一个独立的子节点上（取值相同的样本视为同一个样本）。这样我们就得到了 N 个（基本）不相同的树。从超空间的角度看，这样就是不断地用随机选取的超平面切分样本点，直到所有的样本点都被这些超平面“孤立”起来，即与其他样本点分隔开了。异常值分数的计算公式如下：

$$H(k) = lnk + \xi \quad (2)$$

$$c(n) = 2H(n-1) - \left(\frac{2(n-1)}{n}\right) \quad (3)$$

$$s(x,n) = 2^{-\frac{E(h(x))}{c(n)}} \quad (4)$$

其中，n 为样本个数，ξ欧拉常数，$h(x)$ 为从根节点到 x 节点的路径长度，$H(k)$可以通过公式(1)来估算，$c(n)$ 是二叉搜索树的平均路径长度，$E(h(x))$ 是样本点 x 在孤立森林中所有孤立树的路径长度的平均值。当异常值分数越大，是异常点的可能性越大。使用异常分数，具有以下性质：

1) 如果分数越接近 1，其是异常点的可能性越高；
2) 如果分数都比 0.5 要小，那么基本可以确定为正常数据；
3) 如果所有分数都在 0.5 附近，那么数据不包含明显的异常样本。

2.2.3 异常检测算法实现

该算法使用 python3.6 实现，使用 `sklearn` 库中的 IsolationForest 方法。实现伪码如下：

孤立森林异常检测伪码：

输入：溶解氧时间序列 DO
输出：删除异常数据后溶解氧数据
clf = IsolationForest(random_state=42, contamination=0.025)
//contamination 为异常样本比例，random_state 为状态种子
clf.fit(溶解氧数据)
//pre 返回值：+1 表示正常样本， -1 表示异常样本。
pre = clf.predict(DO)
for i in range(len(pre)):
    if pre[i] == -1:
        标记异常值后删除
返回删除异常数据后溶解氧数据

2.2.4 异常检测结果

按照上述方法，进行孤立森林异常检测后（设置最大异常样本比例为 0.025），检测结果如下图所示：

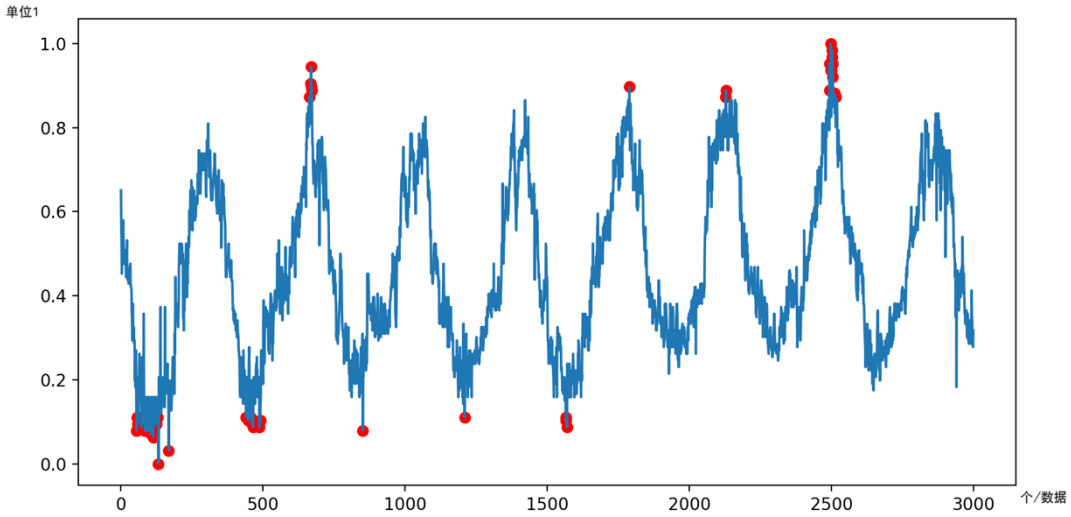


图 2-3 孤立森林算法检测后异常值分布

Figure 2-3 Outlier distribution after isolated forest algorithm detection

总共找出 70 个异常值，处理后共有 2930 个。对于异常检测出来的情况，因为前后数据变化也比较大，采用异常值剔除的方式处理，处理后结果如下:

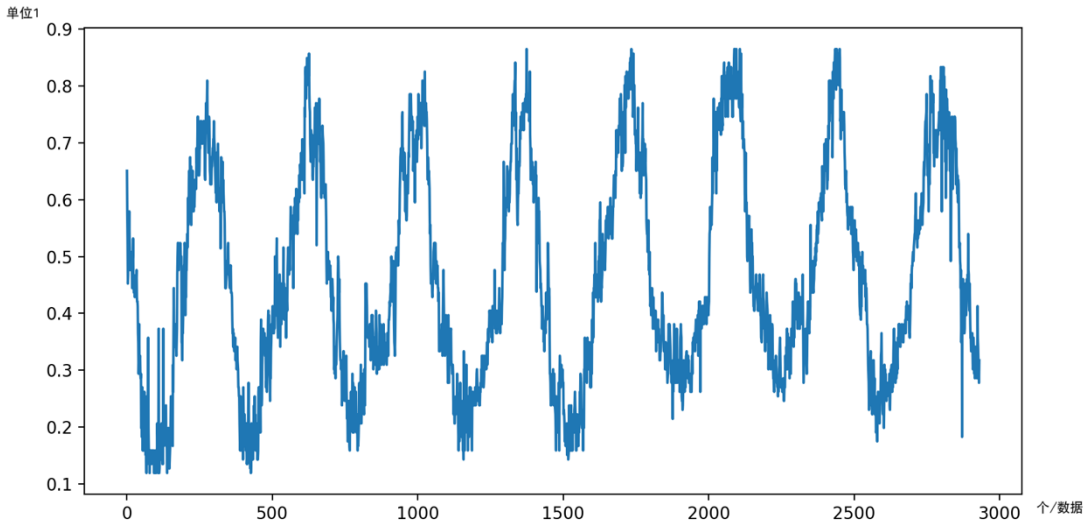


图 2-4 异常值剔除后数据分布

Figure 2-4 Data distribution after outlier removal

3 基于 EEMD-LSTM 的算法设计与模型实现

3.1 长短时记忆网络（LSTM）原理

RNN 之所以称为循环神经网路，是因为一个序列当前的输出与前面的输出也有关[11]。隐藏层之间的节点不再无连接而是有连接的，并且此时此刻的隐藏层的输入不仅包括输入层的输出还包括上一时刻隐藏层的输出。RNN 结构如下图所示，

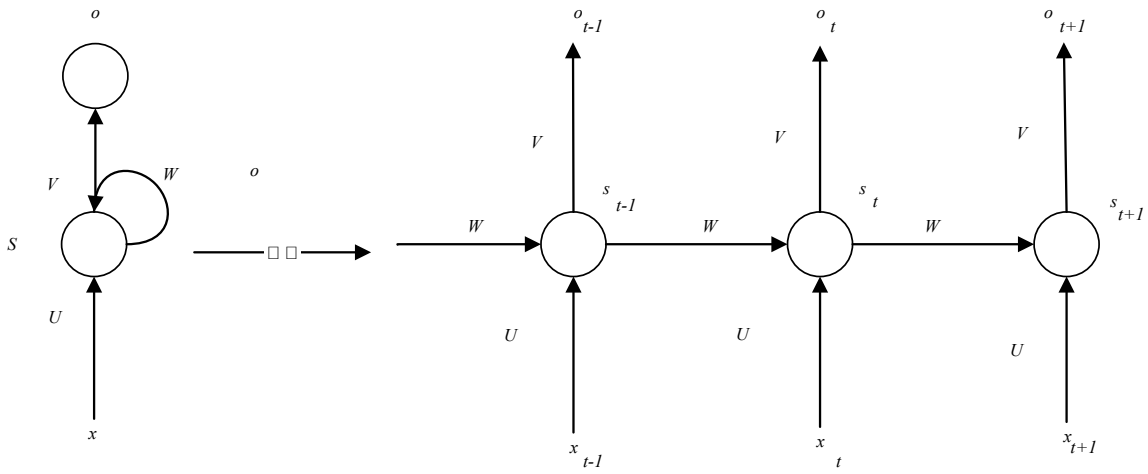


图 3-1 RNN 结构图

Figure 3-1 RNN structure diagram

其中，x、s、o 都是向量，分别代表输入层、隐藏层、输出层的值；U、V、W 都是权重矩阵，分别代表输入层到隐藏层、隐藏层到输出层、隐藏层上一次的值作为这一次的输入的权重。循环神经网络的隐藏层的值 s 不仅仅取决于当前这次的输入 x，还取决于上一次隐藏层的值 s。

理论上，RNN 能够对任何长度的序列数据进行处理。然而在实际中，循环神经网络在处理长时间序列数据的过程中，往往会出现梯度消散的问题。RNN 面临的另一个技术挑战是无法完全处理时间序列的长期依赖，即当前时刻无法从序列中间隔较大的那个时刻获得需要的信息。 LSTM （Long short-term memory，长短时记忆）网络的出现解决了梯度消散问题和长期依赖问题。LSTM 引入了一个的概念，门（gate）[20]。LSTM 靠一些“门”的结构让信息有选择地影响循环神经网络中每个时刻的状态。所谓“门”结构，就是一个使用 sigmoid 的全连接层和一个按位做乘法的操作，这两个操作合起来就是一个“门”结构。LSTM 有三个门，分别是“遗忘门”（forget gate）、“输入门”（input gate）和“输出门”（output gate）。“遗忘门”的作用是让网络“忘记”之前没有用的信息。“输入门”决定哪些信息进入当前时刻的状态。在时间序列经过“遗忘门”和“输入门”的处理之后，LSTM 结构可以决定遗忘什么信息，保留什么信息。

LSTM 在得到当前时刻状态 C_t 之后，需要产生当前时刻的输出，该过程通过“输出门”完成。LSTM 结构如下图所示：

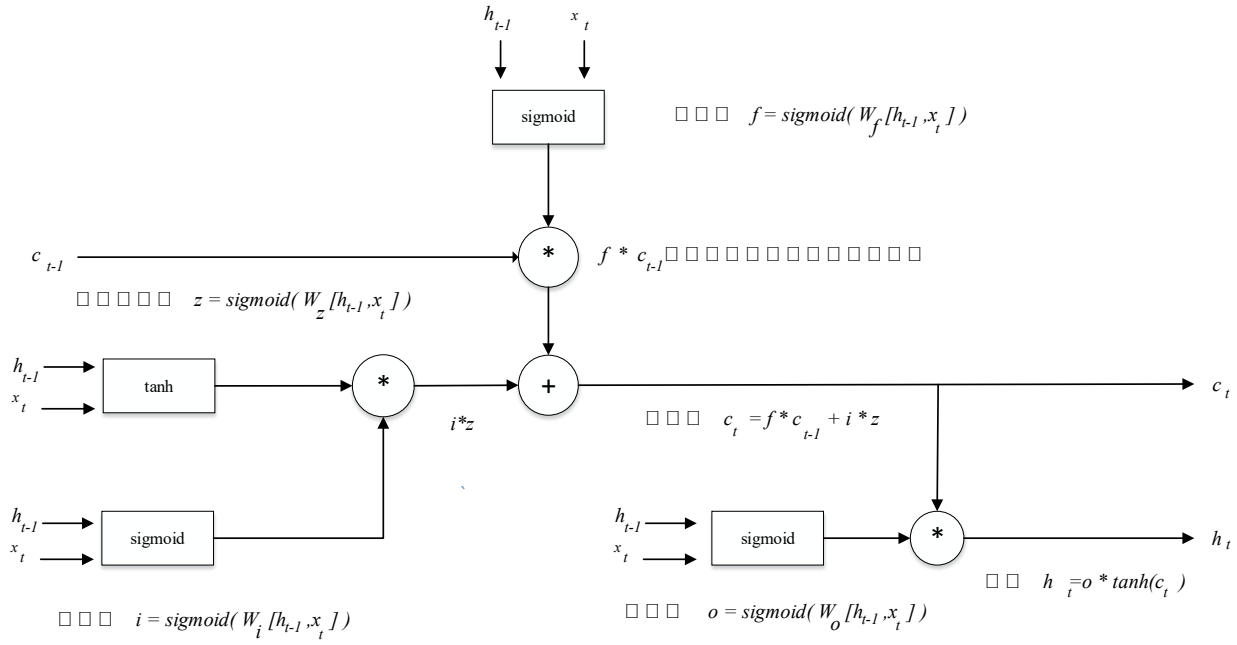


图 3-2 LSTM 单元原理图

Figure 3-2 LSTM unit schematic

其中，x_t 为当前输入，h_{t-1} 为上一时刻的输出，c_{t-1} 为上一时刻状态，c_t 为当前状态，W_i 为 4 个维度为$(2n,n)$的参数矩阵。其中，输入状态值 z、输入门 i、遗忘门 f、输出门 o、输出值计算公式如下：

$$z = tanh\,(W_z[h_{t-1}, x_t]) \quad (5)$$

$$i = sigmoid\,(W_i[h_{t-1}, x_t]) \quad (6)$$

$$f = sigmoid\,(W_f[h_{t-1}, x_t]) \quad (7)$$

$$o = sigmoid\,(Wo[h_{t-1}, x_t]) \quad (8)$$

$$c_t = f * c_{t-1} + i * z \quad (9)$$

$$h_t = o * tanh(c_t) \quad (10)$$

3.2 集合经验模态分解（EEMD）原理

EMD 方法由黄锷等人于 1998 年提出[13]，旨在处理非平稳性非线性信号，该方法分解得到一系列的基本模态分量(Intrinsic Mode Fuction，IMF)和一个信号余量，分解的结果如下：

$$x(t) = \sum_{i=1}^{n} imf_i(t) + res(t) \quad （11）$$

其中，*t* 为时间，*x(t)*为原始数据，*res(t)*为余量。imf 必须满足以下两个条件：

1) 函数在整个时间范围内，局部极值点和过零点的数目必须相等，或最多相差一个；
2) 在任意时刻点，局部最大值的包络（上包络线）和局部最小值的包络（下包络线） 平均值相等且必须为零。

EMD 分解步骤如下：

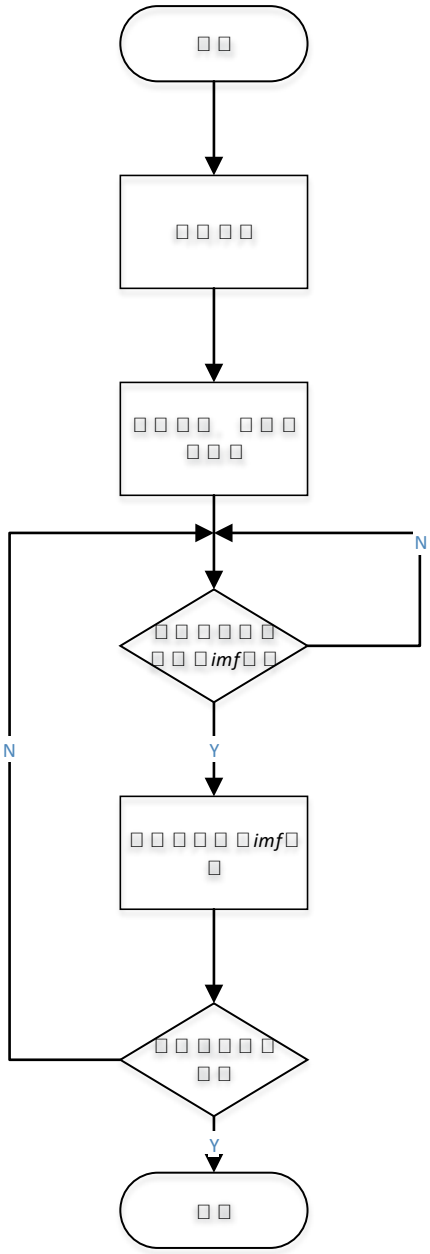


图 3-3 EMD 算法步骤

Figure 3-3 EMD algorithm steps

Wu 等人[14]提出了改进方法以解决 EMD 分解的模态混叠问题，即将满足高斯分布的白噪声加到原始信号中，在这之后再进行 EMD 分解，直至得到最终结果。因为 EEMD 既保留了 EMD 对于非线性、非平稳性时间序列数据的分解效果，同时解决了其模态混叠问题，因此近年来逐渐被用于时间序列预测中。EEMD 分解步骤如下：

EEMD 算法步骤如下：

1) 将正态分布的白噪声加到原始信号;
2) 将加入白噪声的信号作为一个整体,然后进行 EMD 分解,得到各 IMF 分量;
3) 重复步骤 1 和 2,每次加入新的正态分布白噪声序列;
4) 将每次得到的 IMF 做集成平均处理后作为最终结果。

EEMD 算法流程图如下所示：

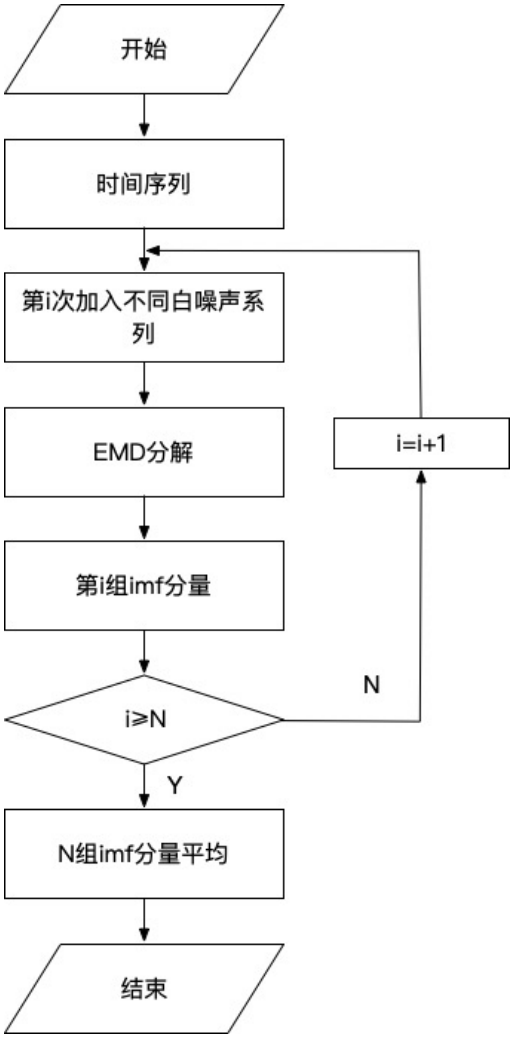


图 3-4 EEMD 算法步骤

Figure 3-4 EEMD algorithm steps

经过集合经验模态分解后的时间序列，可以准确地还原时间序列在不同时间段上的波动特征，提高预测精度[21] 。

3.3 EEMD-LSTM 算法设计与实现

3.3.1 算法设计

为了提高长短时记忆网络（LSTM）的预测精度，解决原始 LSTM 对时间序列预测存在一定的延迟性的问题，本文提出改进的长短时记忆网络（LSTM）的方法，在导入原始溶解氧时间序列数据后，先使用孤立森林异常检测算法进行异常检测，检测后的结果经过 EEMD 分解成若干子序列，针对每个子序列建立 LSTM 子模型，汇总每个子模型的预测结果即为最后的预测结果。改进过后的 LSTM 算法流程图如下所示：

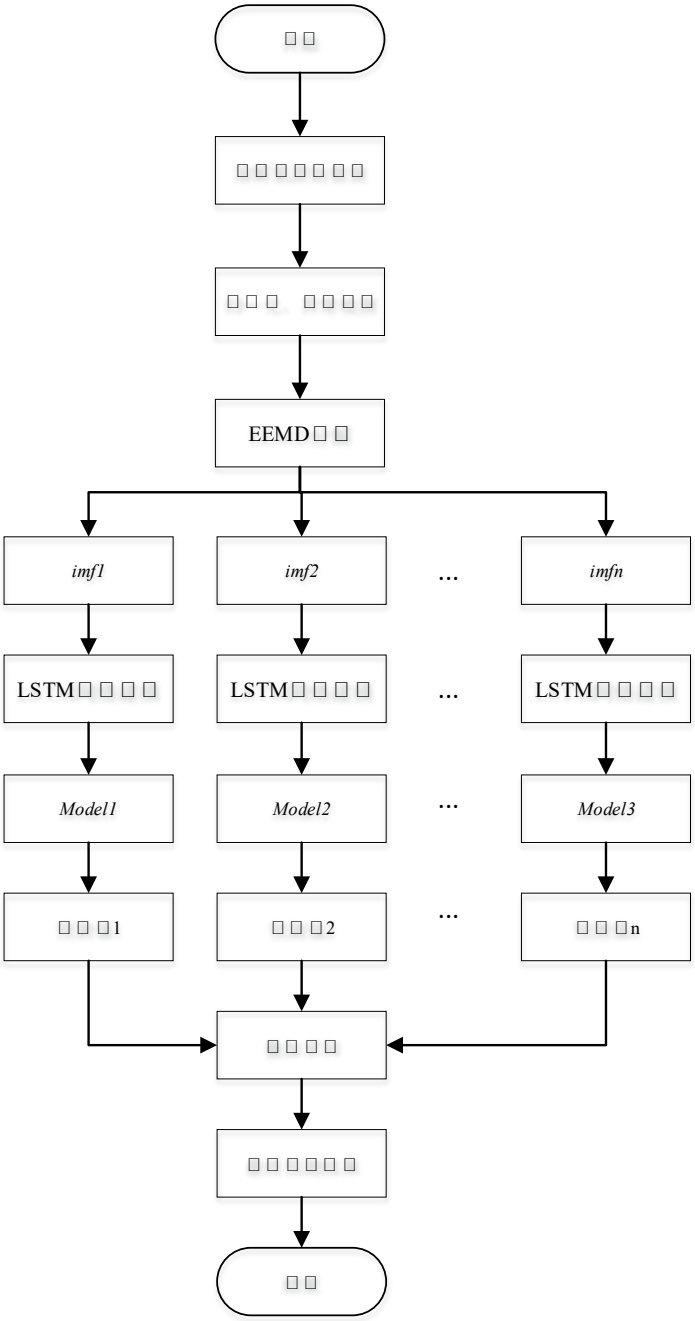


图 3-5 改进的 LSTM 算法流程图

Figure 3-5 Improved LSTM algorithm flow chart

3.3.2 算法实现

算法实现步骤如下：

1) 导入原始溶解氧时间序列数据 *data*；
2) 归一化处理原始数据 *data*，利用孤立森林异常检测算法，对原始数据进行异常检测；
3) 处理后的数据经过集合经验模态分解（EEMD），分解得到 *i* 条 *imf* 子序列；
4) 针对 imf_i 子序列和余项，设置相同的 *lookback_window*(回望窗口，即以过去 *n* 天的溶解氧数据，预测 *n+1* 天溶解氧数据)，分别利用 LSTM 网络构建溶解氧预测模型 $model_i$，得到 *i+1* 个溶解氧预测子模型；
5) 汇总 *i+1* 个溶解氧预测子模型的预测结果 $result_i$，即为最后的预测结果 *Result*。

EEMD-LSTM 算法实现：

输入：溶解氧时序数据
输出：EEMD-LSTM 模型
读入包含溶解氧数值的 csv 文件
整体数据的全部字典类型
返回溶解氧那一列，用字典的方式

scaler_DO = MinMaxScaler(feature_range=(0, 1))
归一化后的溶解氧数据= scaler_DO.fit_transform(溶解氧数据)#归一化处理

eemd = EEMD 分解的实例
imfs = eemd.eemd(归一化后的溶解氧数据,8)#EEMD 分解为 9 个子序列

for imf in imfs:
    依据回望窗口，划分训练集、测试集
    调整训练集、测试集为 LSTM 网络需要的三维数据
    model = LSTM (训练集)#训练模型
    model.save#保存模型

3.3.3 评价标准

为了测试模型的预测能力，我们选择三个统计指标并在测试集中比较它们的值。 它们是 RMSE（Root Mean Square Error，均方根误差），MAE（Mean Absolute Error，平均绝对误差），MAPE（Mean Absolute Percentage Error，平均绝对百分比误差），决定系数 R^2。对于 RMSE 和 MAE，接近 0 意味着更好的性能，而对于 R^2，接近 1 更好，MAPE 是一个相对值，越小越好，在不同模型比较下才有实际意义。

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(y_t - \hat{y_t})^2} \quad (11)$$

$$MAE = \frac{1}{n}\sum_{t=1}^{n}|y_t - \hat{y_t}| \quad (13)$$

$$MAPE = \frac{1}{n}\sum_{t=1}^{n}\frac{|y_t - \hat{y_t}|}{y_t} \quad (14)$$

$$R^2 = 1 - \frac{\sum_{t=0}^{n-1}(y_t - \hat{y_t})^2}{\sum_{t=0}^{n-1}(y_t - \bar{y_t})^2} \quad (15)$$

其中，n 为样本个数，y_t为溶解氧实际值，$\hat{y_t}$为溶解氧预测值，$\bar{y_t}$为样本平均值。

3.3.4 参数选择

为了获取最佳的预测效果，针对网络结构，这里设立了三种不同网络结构进行比对，第一种，仅 50 个 LSTM 单元；第二种，第一层 50 个 LSTM 单元之后，再接 50 个 LSTM 单元；第三种，第一层 50 个 LSTM 单元之后，再接 50 个 BP 单元，三种网络结构分不同的 epochs（10、50、100）、batch_size（1、8、16、32），试验过后，证明第一种网络结构在 epochs=100，batch_size=16 拥有最好的测试效果，其中四项指标分别为 RMSE:0.0205，MAE:0.0160，MAPE:3.9019，R^2:0.9863。

在此基础上，为了进一步提高模型的预测精度，为了确保模型的回望窗口 n，这里又进行了模型的回望窗口测试，即以过去 n 天的溶解氧数据预测底 $n+1$ 天的溶解氧数据，实验数据，如下表所示：

n	**RMSE**	**MAE**	**MAPE**	**R^2**
4	0.0220	0.0146	3.3779	0.9846
5	0.0217	0.0148	3.3962	0.9849
6	0.0212	0.0142	3.2894	0.9857
7	0.0211	0.0144	3.3878	0.9859
8	0.0211	0.0143	3.3231	0.9859
9	0.0211	0.0144	3.3701	0.9859
10	0.0213	0.0147	3.4924	0.9857
11	0.0214	0.0144	3.3539	0.9856
12	0.0212	0.0145	3.3896	0.9858
13	0.0375	0.0280	6.7612	0.9574
14	0.0213	0.0146	3.4115	0.9857

15	0.0217	0.0146	3.3910	0.9853

表 3-1 回望窗口测试

Table 3-1 Lookback window test

实验表明，在 *n* 为 6、7 之间，收敛取得最小值。在兼顾 RMSE、MAPE 的情况下，*n* 为 6 时，具有最好的预测效果，误差最小。

3.4 基于 EEMD-LSTM 算法的模型构建

首先进行归一化处理溶解氧时间序列原始数据，异常检测后，经由 EEMD 分为 8 个 imf 子序列和 1 个余量。分解后的结果如下图所示，前 8 个条曲线为 8 个 imf 子序列：

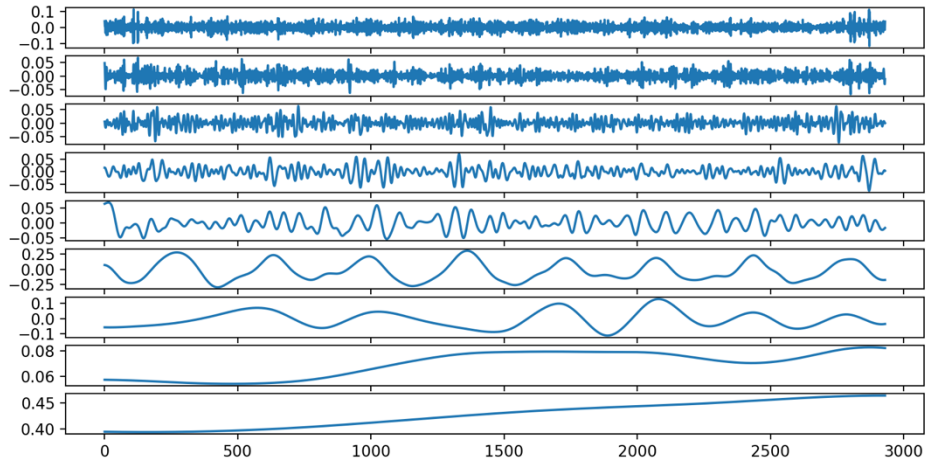


图 3-6 EEMD 分解后结果

Figure 3-6 EEMD decomposition results

在以上结果的基础上，对每一条子序列分别使用 LSTM 建模。基于 Keras 深度学习库、Python3.7 平台，使用试错法进行调参，建立了 50 个 LSTM 单元的深度学习神经网络，激活函数选择 tanh，即双曲正切激活函数，epochs 为 100, batch_size 为 16，得到预测模型，叠加不同子序列预测模型的预测值即为最终结果。

3.5 模型比较

这里选择原始 LSTM 模型、EEMD-BP 模型、BP 模型进行实验比较，使用相同的测试集和训练集，经过相同的预处理，实验结果如下图所示：

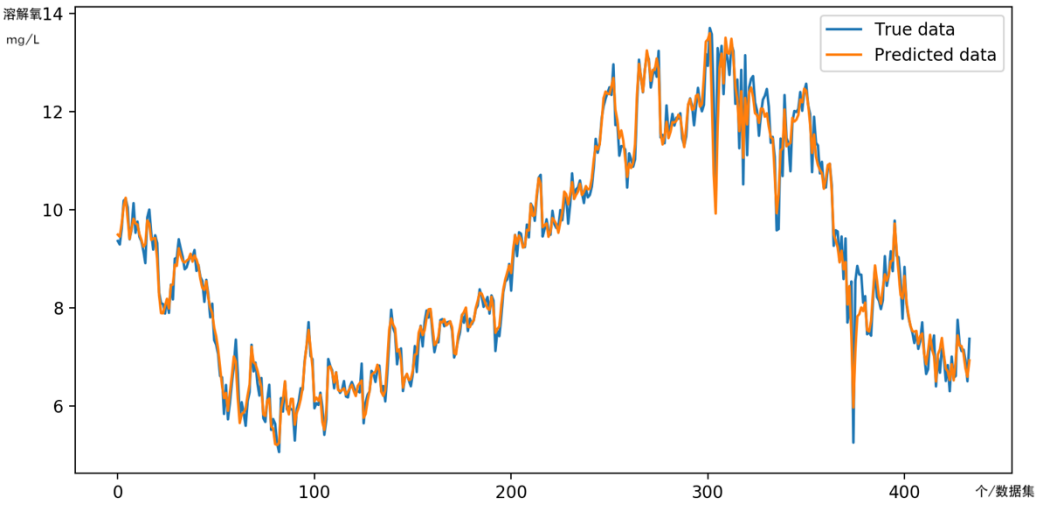


图 3-7 EEMD-LSTM 模型结果图

Figure 3-7 EEMD-LSTM model result

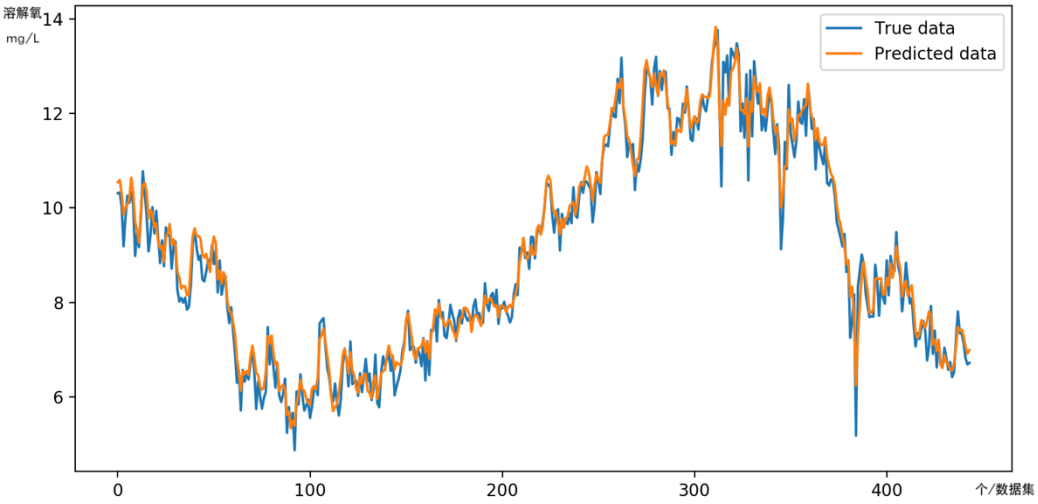


图 3-8 EEMD-BP 模型结果图

Figure 3-8 EEMD-BP model result

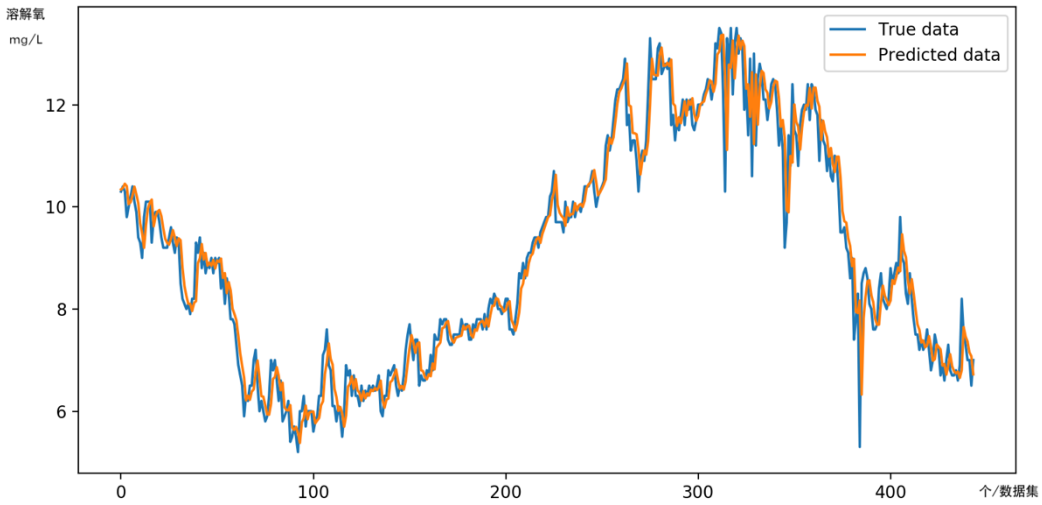


图 3-9 LSTM 模型结果图

Figure 3-9 LSTM model result

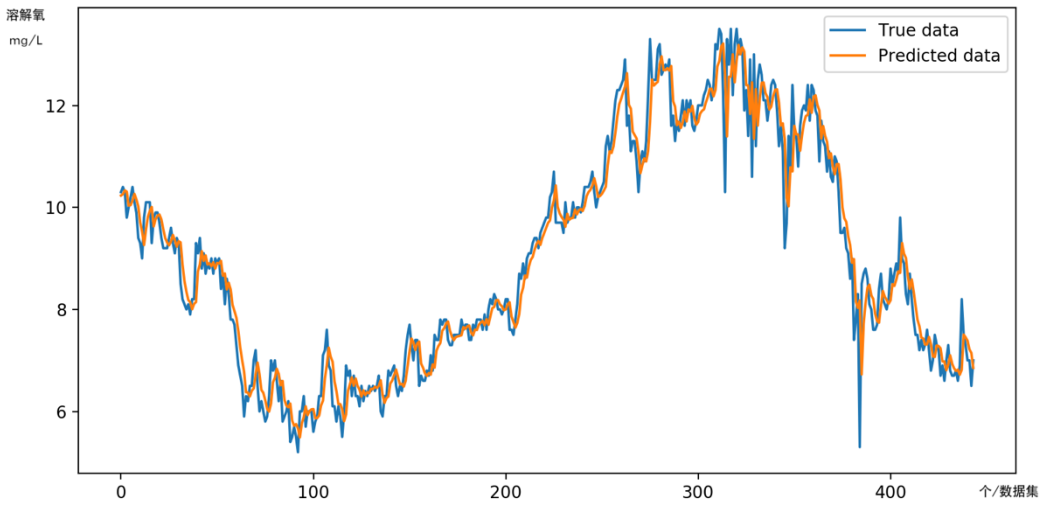


图 3-10 BP 模型结果图

Figure 3-10 BP model result

可以看出，改进后的 EEMD-LSTM 模型得到的预测值和真实数据十分契合，尤其是在时间序列发生突变的情况下，可以得到误差更小的预测数据，原始 LSTM 模型也可以较好的预测真实值的走势，虽然误差比改进后的 LSTM 模型更大。改进后的 BP 模型，较之原始 BP 模型，大部分预测值与真实值相接近，但是预测走势不及原始 BP 模型。原始 BP 模型虽然走势与真实值相拟合，但是大多数预测值和真实值都有相似的偏差。回到 1.4 节目前存在的问题，使用 LSTM 进行溶解氧预测研究，普遍存在对溶解氧预测存在一定的延迟性，直观表现为图像上的平移错位。其根本原因在于，LSTM 网络无法

精准地探测到时间序列的波动程度，以至于对上一时刻预测的结果，可能在对这一时刻才有所体现。引入 EEMD 算法改进 LSTM 网络后，可以看出，LSTM 本身的延迟得到改善，并在对极值预测表现更为精准。

不同模型的精度数据如表 2 所示，可以看出，EEMD-LSTM 模型相对于原始 LSTM 模型，RMSE 降低了 47.64%，MAPE 降低了 48.65%；相对于 EEMD-BP，MAPE 降低了 27.87%。EEMD-LSTM 模型在四项指标中，均具有最好的预测效果。综上所述，EEMD-LSTM 模型最有更高的预测精度。

	RMSE	**MAE**	**MAPE**	**R^2**
EEMD-LSTM	0.0211	0.0143	3.3295	0.9858
EEMD-BP	0.0242	0.0188	4.6163	0.9807
LSTM	0.0403	0.0276	6.4849	0.9464
BP	0.0401	0.0284	6.7019	0.9468

表 3-2 不同模型预测精度

Table 3-2 Prediction accuracy of different models

3.6 加入高斯噪声后的补充实验

在使用上述数据集后，为了进一步提高模型的泛化能力，这里选择在该数据集中添加高斯噪声，使用加入高斯噪声后的数据集再次验证 EEMD-LSTM 模型的预测精度。噪声数据的多少是由信噪比（Signal Noise Ratio，SNR）衡量，单位分贝（dB），信噪比公式计算如下：

$$SNR = 10log_{10}\frac{\sum_{t=0}^{n-1}(x_t)^2}{\sum_{t=0}^{n-1}(y_t)^2} \quad （16）$$

其中，t 代表每一时刻，n 为样本集总数，x_t 表示干净信号，y_t 表示噪声信号。一般来说，信噪比越大，说明混在信号里的噪声越小。本次实验，向数据集中加入 5dB 的噪声数据。加入噪声后的数据和真实数据对比如 3-11 图，图中标记了明显变化的几处，这里因为展示 3000 条加入噪声后的数据，密度过大，图中较难看出清晰变化。加入噪声后的数据和对应真实数据的差的绝对值之和为 59.45（这里是对归一化后的数据加入噪声）。

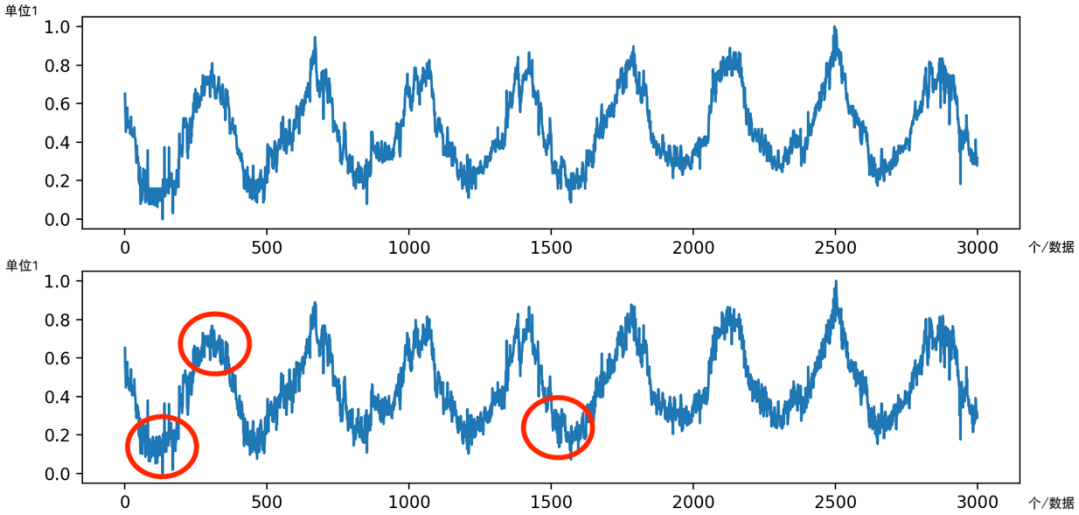


图 3-11 真实数据和加入噪声后的数据对比图

Figure 3-11 Comparison between real data and data after adding noise

因为加入噪声数据后，数据已经失真，这里不再进行异常检测，直接进行 EEMD 分解。以下是加入噪声后的数据 EEMD 分解的结果。

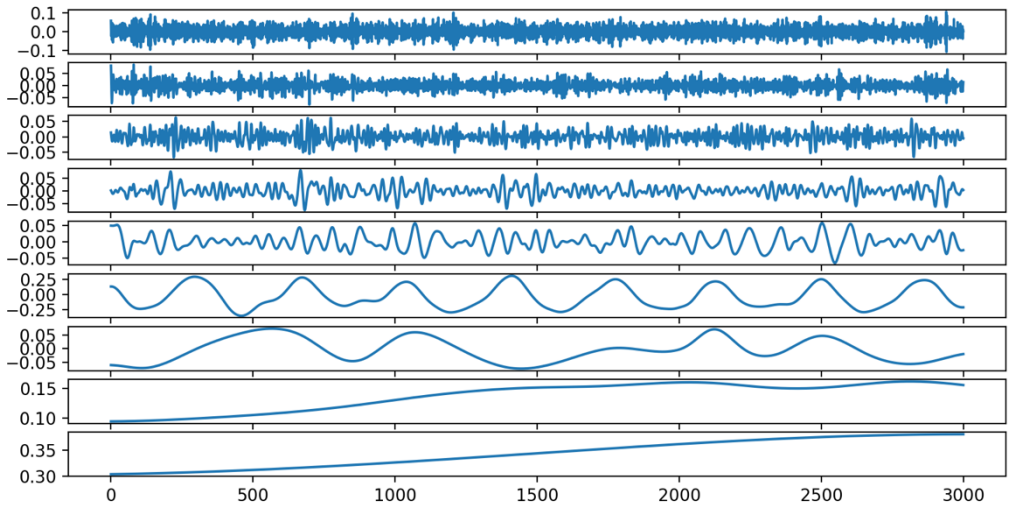


图 3-12 加入噪声后的数据 EEMD 分解结果

Figure 3-12 EEMD decomposition result of data after adding noise

对以上结果应用 3.5 中的模型进行预测，预测结果和指标结果如下：

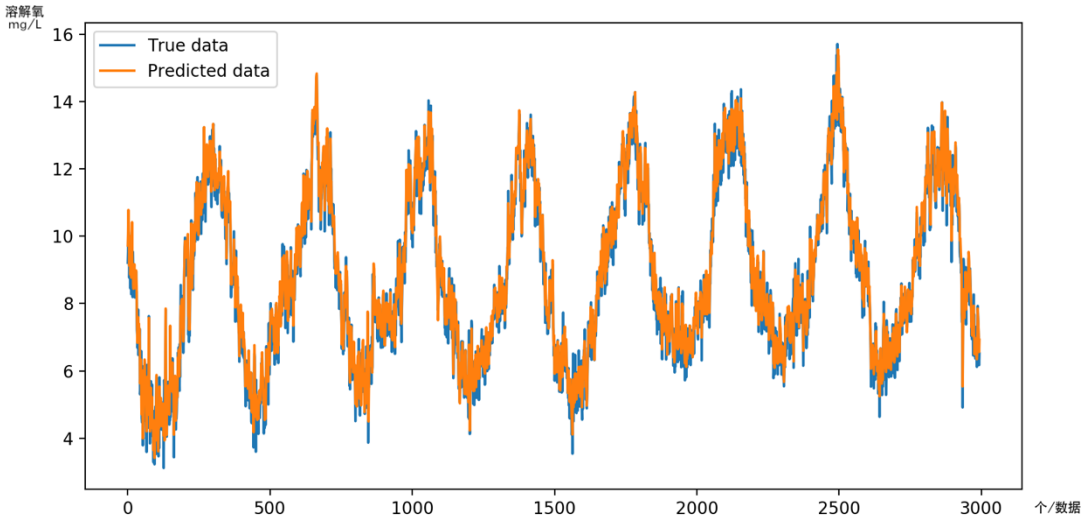


图 3-13 EEMD-LSTM 模型对加入噪声后数据的预测结果

Figure 3-13 EEMD-LSTM model predicts the results after adding noise

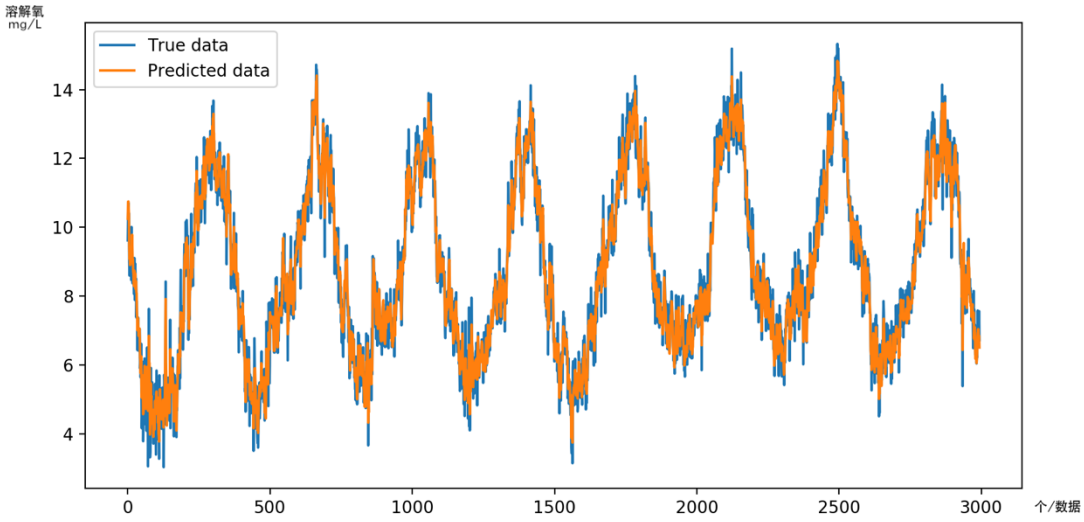


图 3-14 EEMD-BP 模型对加入噪声后数据的预测结果

Figure 3-14 EEMD-BP model predicts the results after adding noise

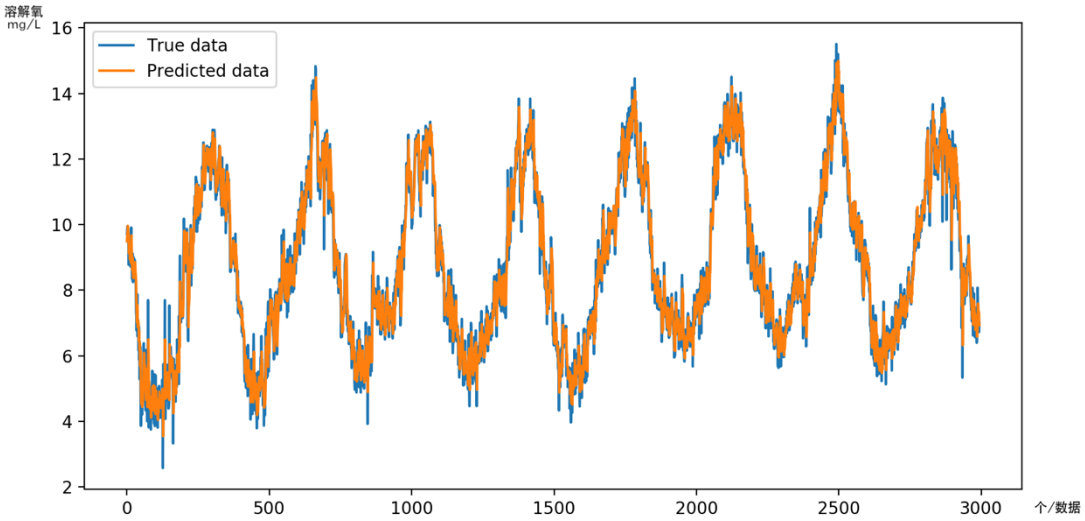


图 3-15 LSTM 模型对加入噪声后数据的预测结果

Figure 3-15 LSTM model predicts the results after adding noise

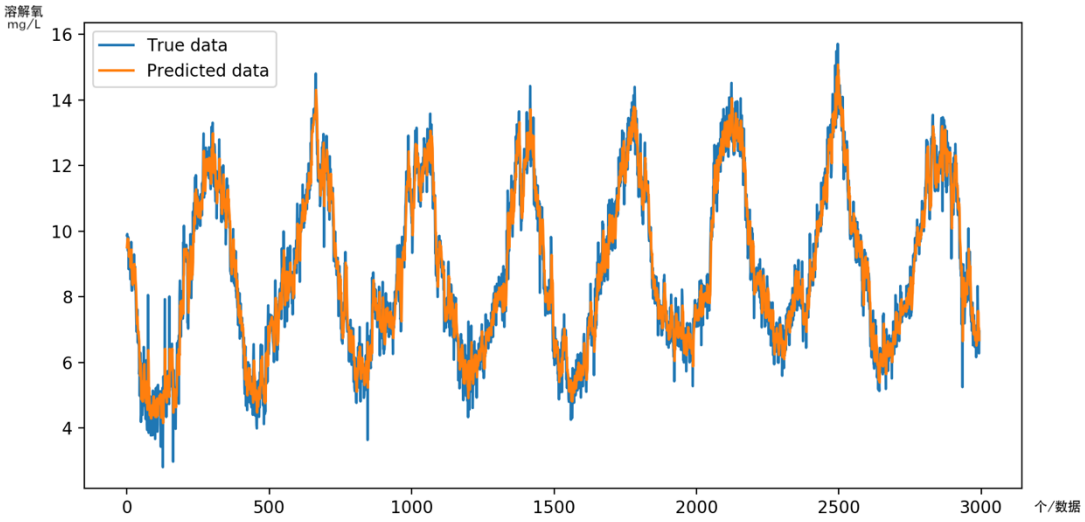


图 3-16 BP 模型对加入噪声后数据的预测结果

Figure 3-16 BP model predicts the results after adding noise

使用加入噪声后的数据进行预测，各项指标结果如下：

	RMSE	MAE	MAPE	R^2
EEMD-LSTM	0.0231	0.0179	5.9020	0.9864
EEMD-BP	0.0284	0.0226	7.3666	0.9799
LSTM	0.0458	0.0350	5.0623	0.9427
BP	0.0465	0.0356	5.0258	0.9459

表 3-3 加入噪声后的数据不同模型的预测精度

Table 3-3 The prediction accuracy of different models of data after adding noise

可以看出，在针对加入噪声后的数据使用模型进行预测时，改进过后的模型 EEMD-LSTM 均具有最好的预测效果，RMSE 相较于原始 LSTM 提高了 49.56%，MAE 相较于原始 LSTM 提高了 48.86%，加入 EEMD 分解后的提升效果明显；虽然原始 LSTM 网络模型、原始 BP 模型的 MAPE 数值较低，但是他们的 RMSE 值、MAE 远高于加入 EEMD 分解后的模型，且在数据的相关性上，加入 EEMD 分解后有较为明显的提升。单从真实数据和预测数据的分布图可以看出，改进过后的模型 EEMD-LSTM 可以更好地拟合数据真实值的走势。

3.7 实现部分总结

本文提出了一种改进后的 LSTM 模型，即 EEMD-LSTM 模型。该方法在获取原始溶解氧时间序列后并预处理后，经过 EEMD 分解为若干子序列，并对其分别建立 LSTM 预测模型，叠加个各个模型的预测结果即可获取最终的预测结果。在获取江苏无锡长江水质实时监测站溶解氧数据后展开实验，选取原始 LSTM 模型、改进后的 BP 模型、原始 BP 模型作为对比，实验表明，EEMD-LSTM 模型具有最小的预测误差，更好的模拟溶解氧时间序列的走势，具有最好的预测效果。